

D RTP 仅在环境 reset 阶段分配训练暴露，不改策略学习接口



保持不变: actor · critic · PPO objective · reward · observation · action interface · transition